

Predicción de Ventanas de Cosecha

Mandarinas · Valle del Elqui · Pisco Elqui

ML + Deep Learning · Datos Meteorológicos 2022–2024

100%	99%	12.6%	20
Accuracy RF	Accuracy DL	Horas con Ventana	Épocas Entrenamiento

Paragraph('caseSensitive': 1 'encoding': 'utf8' 'text': 'Componente' 'frags': [ParaFrag(__tag__='para', bold=1, fontName= 'Helvetica-Bold', fontSize=9, greek=0, italic=0, link=[], rise=0, text ='Componente', te xtColor=Color(.345 098,.65098,1,1), us_lines=[])] 'style': 'bulletText': None 'debug': 0) #Paragraph Paragraph('caseSensitive': 1 'encoding': 'utf8' 'text': 'Detalle' 'frags': [ParaFrag(__tag__='para', bold=1, fontName='Helvetica-Bold', fontSize=9, greek=0, italic=0, link=[], rise=0, text='Detalle', textColor=Color(.345098,.65098,1,1), us_lines=[])] 'style': 'bulletText': None 'debug': 0) #Paragraph	
Dataset	ESTACIONPISCOELQUI · 3 años horarios · 28,560 registros
Variables	Temperatura, Humedad Relativa, Viento, Radiación Solar, Punto de Rocío
Target	VentanaRecomendada (binario): T=15–25°C · HR>60% · V<2.78m/s · Rad<50W/m²
Modelo 1	Random Forest (n=100) · Accuracy 100% · F1 ponderado 1.00
Modelo 2	Red Neuronal Densa (16→8→1) · Accuracy 99% · 20 épocas · Adam lr=0.001
Aplicación	Planificación óptima de cosecha nocturna/madrugada · Reducción pérdidas post-cosecha

1. Variables Meteorológicas · Estación Pisco Elqui

El dataset proviene de la **Estación Meteorológica Pisco Elqui**, ubicada en el Valle del Elqui (IV Región, Chile), con registros horarios desde enero 2022 hasta diciembre 2024 (3 años). Las variables clave son: **temperatura del aire** (1.5m), **humedad relativa** (1.5m), **velocidad del viento** (2m), **radiación solar** (2m) y **punto de rocío** (2m). Los patrones diarios muestran picos de temperatura al mediodía y radiación solar máxima entre las 11:00 y 15:00 horas, lo que define las restricciones de la ventana de cosecha.




Fig. 1 — Serie temporal de 500 registros muestreados para las 4 variables principales. La línea blanca punteada indica la media.
Patrones diurnos claramente visibles en temperatura y radiación.

2. Análisis Temporal de Ventanas de Cosecha

La **ventana de cosecha recomendada** se define por criterios agronómicos para preservar la calidad de la mandarina: temperatura entre 15–25°C, humedad relativa mayor al 60%, viento menor a 2.78 m/s (10 km/h) y radiación solar menor a 50 W/m². Solo el **12.6% de las horas** cumple simultáneamente todas estas condiciones, concentrándose principalmente en horas de la **madrugada y primera hora de la mañana (00:00–07:00h)**, cuando la temperatura es suave y la radiación solar es nula. Los meses de otoño (abril–junio) presentan mayor disponibilidad de ventanas óptimas.




Fig. 2 — (Izq.) Porcentaje de horas con ventana recomendada por hora del día: verde >30%, amarillo >10%, rojo <10%. (Der.) Distribución mensual con valores exactos.

3. EDA: Condiciones en Ventana vs Fuera de Ventana

Los boxplots confirman la separación estadística entre las distribuciones dentro y fuera de la ventana de cosecha. Durante las horas de ventana óptima, la **temperatura** se concentra en el rango 15–25°C, la **humedad** supera el 60%, el **viento** es inferior a 2.78 m/s y la **radiación** es prácticamente nula. Esta clara separación entre clases explica el altísimo rendimiento de los modelos ML/DL: las clases son linealmente separables en el espacio de features.




Fig. 3 — Boxplots comparativos: verde = horas con ventana recomendada, rojo = horas fuera de ventana. La separación es estadísticamente significativa en todas las variables.

4. Modelado ML: Random Forest

El modelo **Random Forest** (100 árboles, random_state=42) alcanza **100% de accuracy** en el conjunto de prueba (20% de los datos). La **Radiación Solar** es la feature más importante (>0.35), seguida por **Temperatura** y **Hora del día**, lo cual es consistente con la definición agrónomca de la ventana. La matriz de confusión muestra clasificación perfecta en la clase mayoritaria y casi perfecta en la clase minoritaria (ventanas positivas, ~12.6% del dataset). El alto accuracy se explica por la naturaleza **determinista** de la etiqueta: es una función booleana exacta de las features.




Fig. 4 — (Izq.) Feature importance del Random Forest ordenada ascendentemente: Radiación Solar domina la predicción. (Der.) Matriz de confusión: clasificación casi perfecta.

5. Modelado DL: Red Neuronal Dense

La **red neuronal** (arquitectura Dense 16→8→1, activación ReLU/Sigmoid, optimizador Adam $\text{lr}=0.001$, binary crossentropy) alcanza **99.65% de accuracy** en validación al finalizar las 20 épocas de entrenamiento. Las curvas de loss y accuracy muestran **convergencia rápida y estable** sin signos de overfitting: la brecha entre train y validación es mínima desde la época 5. La red neuronal tiene mayor dificultad que RF en la clase minoritaria ($F1=0.93$ vs 0.99) debido al desbalance de clases, lo que sugiere aplicar técnicas como SMOTE o `class_weight` en trabajos futuros.

MODELO DL — Curva de Entrenamiento · Red Neuronal (16→8→1)




Fig. 5 — Curvas de entrenamiento de la red neuronal: accuracy (izq.) y loss (der.) por época para train y validación. Convergencia limpia sin overfitting.

6. Predicciones Temporales y Aplicación Práctica

El modelo exporta las predicciones horarias en `predicciones_modelo.csv`, permitiendo al productor planificar la cosecha con anticipación. El análisis semanal revela patrones estacionales: invierno y primavera concentran más horas favorables. La distribución predicha vs real confirma la precisión del modelo.




Fig. 6 — (Arriba) Horas con ventana recomendada por semana durante 3 años. (Abajo) Comparación distribución real vs predicha por el Random Forest.

Conclusiones y Mejoras Propuestas

#	Hallazgo	Impacto / Recomendación
1	RF 100% accuracy · DL 99.65%	Ambos modelos listos para producción como sistema de alerta
2	Solo 12.6% de horas son ventana óptima	Planificar cosecha principalmente en madrugada (00:00–07:00h)
3	Radiación Solar es la feature clave	Instalar sensor de radiación de alta precisión en campo
4	Otoño concentra más ventanas (Abr–Jun)	Ajustar calendario de cosecha para maximizar calidad post-cosecha
5	Desbalance de clases afecta al DL	Aplicar SMOTE o class_weight para mejorar recall en clase positiva

F. Ardiles para M. Valenzuela · Python: scikit-learn · TensorFlow/Keras · pandas · GitHub: franciscoantonioardiles-ctrl